Coletor Multibase de Artigos Científicos

Aquisição em APIs acadêmicas e classificação com LLM local

Arthur Cadore Matuella Barcella

ITA – TE-251 – Projeto final

7 de novembro de 2026



Sumário

Visão geral

Etapa 1 – Aquisição

Etapa 2 – Classificação

Resultados e conclusão


busca
→ filtro → deduplicação → base
Visão geral
n ≈ 1.284 artigos

Motivação e objetivo

Motivação: uma revisão bibliográfica exige repetir a mesma busca em várias bases, cada uma com sintaxe, limites de taxa e formato de resposta próprios, e depois juntar, deduplicar e triar centenas de resultados à mão.

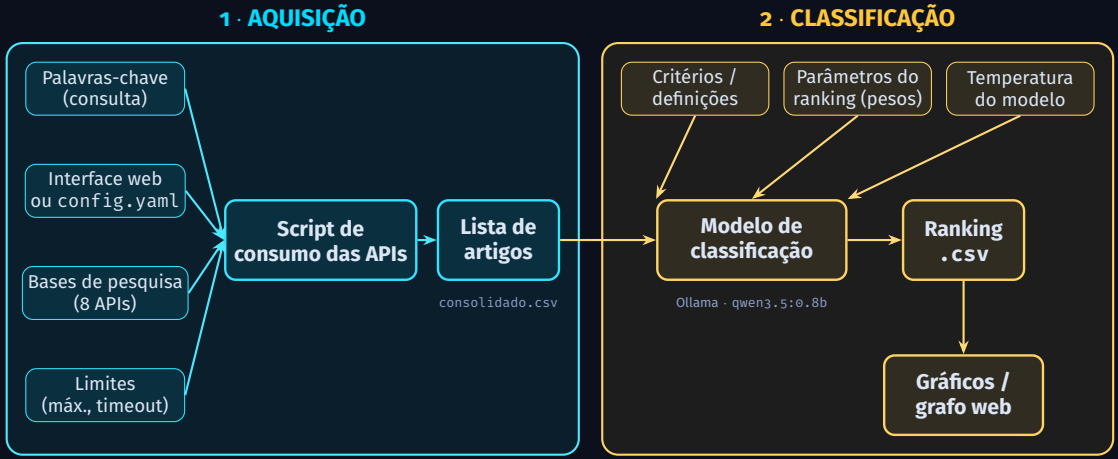
O que o coletor faz

- Recebe **uma** consulta booleana e a traduz para cada base.
- Busca em paralelo em 8 APIs acadêmicas.
- Grava um CSV por base e um `consolidado.csv` sem duplicatas.
- Classifica cada artigo com um LLM local e gera `ranking.csv`.

Princípios de projeto

- Uma base que falha nunca derruba a execução.
- Respeito aos limites de cada API (taxa adaptativa).
- Segredos só no `.env`, nunca em logs ou CSVs.
- Triagem sem enviar dados a serviços externos (Ollama).

Arquitetura em dois blocos



consulta → tradução por base → paginação
normalização → enriquecimento → deduplicação

título + resumo + critérios → aderência (0; 0,5; 1)
com citação literal do resumo → score → ranking



Etapa 1 – Aquisição

Bases consultadas

Base	Interface	Credencial	Taxa (req/s)
OpenAlex	REST JSON, `cursor`	`OPENALEX_API_KEY` (obrigatória)	10
Semantic Scholar	REST JSON + `/paper/batch`	`S2_API_KEY` (opcional)	1
Crossref	REST JSON, `offset`	e-mail (pool *polite*)	3 (1 sem e-mail)
arXiv	Atom XML	nenhuma	0,33
PubMed	E-utilities (`esearch`+`efetch`)	`NCBI_API_KEY` (opcional)	3 (9 com chave)
Europe PMC	REST JSON, `cursorMark`	nenhuma	2
CORE	REST JSON, `offset`	`CORE_API_KEY` (opcional)	0,5 (2 com chave)
DOAJ	Lucene, até 1.000 resultados	nenhuma	2
OpenCitations	enriquecedor (referências, citações)	token opcional	3

SciELO foi avaliada e desabilitada: a API não tem busca por palavra-chave e o portal de busca proíbe robôs (`robots.txt`).

Consulta, paralelismo e limites de taxa

Uma consulta, oito dialetos

- Sintaxe única: aspas, AND/OR, parênteses.
- Ex.: `SAR AND Agricultura` vira `all:SAR AND all:Agricultura` no arXiv e `query.bibliographic=SAR Agricultura` no Crossref.
- Filtros (ano, tipo, idioma, acesso aberto) nativos quando a base suporta; senão, aplicados localmente.

Orquestração

- Uma tarefa `asyncio` por base; falha isolada.
- CSV gravado em lotes, à medida que as páginas chegam.
- Cache HTTP em disco por 24 h.

Limitador adaptativo (por base)

- *Token bucket* + semáforo de concorrência.
- **429**: taxa cai pela metade; respeita `Retry-After`.
- **5xx / timeout**: backoff exponencial com *jitter*.
- Até 6 tentativas por página; depois, status `parcial`.
- +25 % após 20 sucessos seguidos, sem passar da taxa inicial.
- Prazo global: `timeout_pesquisa_s` (300 s na interface).

Normalização, enriquecimento e consolidação

Normalização

- Cada resposta é mapeada para um esquema único de colunas.
- Mapeamento escrito a partir de respostas reais gravadas no teste prático.
- Resumo em texto plano; idioma em ISO 639-1.

Enriquecimento

- Referências nativas quando a base informa.
- IDs OpenAlex convertidos para DOI em lote.
- OpenCitations: referências e contagem de citações.
- Texto completo (CORE com chave, Europe PMC OA).

Consolidação

- Mesmo artigo: DOI, PMID, PMCID ou ID arXiv iguais, ou título ($\geq$ 5 palavras) + ano.
- Registros fundidos numa só linha, com prioridade por base.
- Só entram artigos com DOI **e** resumo.
- Saída: `consolidado.csv`, 16 colunas.

Saídas de cada execução: `<base>.csv` · `consolidado.csv` · `relatorio.md/.json` · `execucao.log` · `config_usada.yaml`

busca
→ filtro → deduplicação → base

Etapa 2 – Classificação

n = 1.284 artigos

Triagem com LLM local

Para cada linha do consolidado

1. Monta o *prompt* com critérios, título, resumo e palavras-chave.
2. O modelo (Ollama, padrão `qwen3.5:0.8b`) devolve JSON estruturado: justificativa, citação e aderência.
3. A citação precisa aparecer **literalmente** no resumo; senão, a resposta é rejeitada.
4. Falha num artigo vira `llm_status=erro` e não interrompe os demais.

Aderência aos critérios

```
llm_match = 1     incluido
llm_match = 0,5   duvidoso
llm_match = 0     excluido
```

Parâmetros na interface

- Critérios de inclusão e exclusão (texto livre).
- Temperatura de 0 a 1 (padrão 0,1; 0 = reprodutível).
- Modelo escolhido entre os instalados no Ollama.

Score do ranking

$$\text{score} = w_a \underbrace{m}_{\text{aderência}} + w_r \underbrace{\hat{y}}_{\text{recência}} + w_c \underbrace{\hat{c}}_{\text{citações/ano}} + w_t \underbrace{v_{\text{tipo}}}_{\text{tipo}}$$

$$\text{padrão:} \quad \text{score} = 0{,}70\, m + 0{,}10\, \hat{y} + 0{,}10\, \hat{c} + 0{,}10\, v_{\text{tipo}}$$

$$\hat{c} = \text{minmax}\left(\log\left(1 + \frac{n_{\text{citações}}}{\text{ano atual} - \text{ano} + 1}\right)\right)$$

- Pesos padrão: $w_a = 0{,}70$ e $w_r = w_c = w_t = 0{,}10$.
- Ajustáveis por execução: somam 100 %, aderência ≥ 50 %.
- Recência e citações: min-max entre os artigos do consolidado.
- Dado ausente (ano, citações ou tipo) recebe valor neutro 0,5.

Valor por tipo de publicação (padrão)

artigo	1,0	livro/capítulo	0,6
revisão	1,0	preprint	0,5
conferência	0,8	outros	0,4

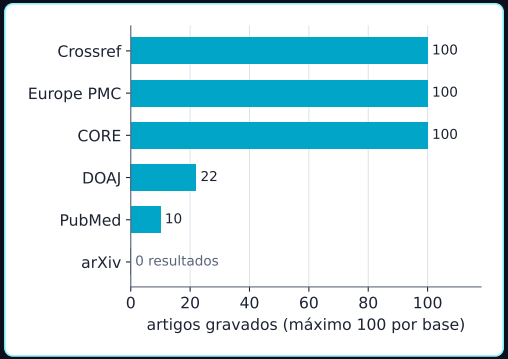
`ranking.csv` = 16 colunas do consolidado + `llm_label`, `llm_match`, `llm_justification`, `llm_score`, `llm_status`, ordenado por score.



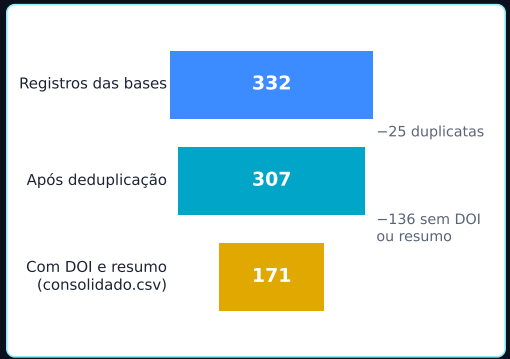
Resultados e conclusão

Execução real: SAR AND Agricultura

Artigos gravados por base



Funil da consolidação



Execução de 31/10/2026, 100 artigos por base, sem filtros: 197 s no total; 15 artigos encontrados em 2 ou mais bases. OpenAlex e Semantic Scholar falharam (HTTP 401 por chave e HTTP 429) sem interromper as outras seis bases. Distribuição de rótulos do ranking: [executar a triagem LLM nesta consulta e incluir o resultado].

Limitações e conclusão

Limitações

- Bases sem chave (Semantic Scholar) sofrem 429 com frequência.
- Mesma referência pode aparecer como DOI e como `pmid:`.
- Triagem usa só título e resumo; modelo pequeno pode errar.
- Precisão da triagem: [comparar com rotulação manual].

Conclusão

- Uma consulta alimenta 8 bases em paralelo, com falhas isoladas.
- Resultado único e deduplicado em `consolidado.csv`.
- Triagem local e auditável: cada decisão traz uma citação do resumo.
- Ranking configurável e grafo de referências na interface web.

Obrigado!

Código e especificação: `README.md` e `ESCOPO.md` do repositório.